

Exercício 1. Mostre que no modelo de regressão linear simples, os componentes do vetor de estimadores mínimos quadrados, $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ coincidem com os estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ apresentados nos livros de estatística básica.

Exercício 2. Seja $\mathbf{y} \sim N_n(\mathbf{X}\beta, \sigma I_n)$ com \mathbf{X} de posto completo $(k+1)$. Prove que

$$(\hat{\beta} - \beta)' \frac{\mathbf{X}'\mathbf{X}}{\sigma} (\hat{\beta} - \beta) \sim \chi_{k+1}^2.$$

Exercício 3. Sejam

$$\begin{aligned} y_1 &= \theta + \epsilon_1 \\ y_2 &= 2\theta - \gamma + \epsilon_2 \\ y_3 &= \theta + 2\gamma + \epsilon_3 \end{aligned}$$

onde $E(\epsilon_i) = 0$, $i = 1, \dots, 3$. Expresse este modelo como um modelo linear geral e determine os estimadores de mínimos quadrados de θ e γ .

Exercício 4. No modelo de regressão linear simples com as suposições usuais, determine o estimador de máxima verossimilhança de β_0 e β_1 sob a hipótese $H_0 : \beta_0 = 2$.

Exercício 5. Considere o modelo linear geral, em que $\epsilon \sim N_n(0, \sigma \mathbf{I})$, $y_i = \beta_0 + \beta_1 x_{i1}^* + \beta_2 [x_{i1}^*]^2 + \epsilon_i$ e $x_{i1}^* = x_{i1} - \sum_{i=1}^n x_{i1}/n$.

- (a) Determine o estimador de mínimos quadrados de β_0 e β_1 sob a hipótese $H_0 : \beta_2 = 1$.
- (b) Determine o estimador de máxima verossimilhança de β_1 e β_2 sob a hipótese $H_0 : \beta_0 = 1$, assumindo que $\sigma^2 = 1$.

Exercício 6. Considere o modelo linear geral de posto completo com intercepto, em que $\epsilon \sim N_n(0, \sigma \mathbf{I})$. Mostre que $\sum_{i=1}^n \epsilon_i^2 = \text{SQRes} + (\hat{\beta} - \beta)^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \beta)$.

Exercício 7. Deseja-se comparar dois métodos de ensino A e B e com esse objetivo, aplicou-se uma prova a n_1 alunos sujeitos ao método de ensino A e n_2 alunos sujeitos ao método de ensino B. Admitindo o modelo

$$y_i = \beta_0 + \beta_1 w_i + \epsilon_i, \quad i = 1, \dots, n$$

com ϵ_i e ϵ_j independentes para $i \neq j$, $\epsilon_i \sim N(0, \sigma)$ e

$$w_i = \begin{cases} 0 & \text{para o método A e} \\ 1 & \text{para o método B} \end{cases}$$

e y_i a nota da prova do i -ésimo aluno.

- (a) Qual o significado de β_0 e β_1 ?
- (b) Obtenha o ENVVUM da diferença das notas médias para alunos sujeitos aos métodos A e B, justificando sua resposta.
- (c) Construa um teste de hipóteses para a igualdade das notas médias seguindo os dois métodos, contra a hipótese alternativa de que as médias são diferentes. Utilize a forma geral $\mathbf{C}\beta = \mathbf{t}$.
- (d) Prove que o teste do item (c) é equivalente ao teste t de igualdade de médias para amostras independentes.

Exercício 8. Considere o modelo

$$\begin{aligned}y_1 &= \theta_0 + \epsilon_1 \\y_2 &= \theta_0 + \theta_1 + \epsilon_2 \\y_3 &= \theta_0 + \theta_2 + \epsilon_3 \\y_4 &= \theta_0 + \theta_1 + \theta_2 + \epsilon_4\end{aligned}$$

com $\epsilon = (\epsilon_1, \epsilon_2, \epsilon_3, \epsilon_4)' \sim N(0, \sigma \mathbf{I})$.

Obtenha o teste para avaliar se $H_0 : \theta_1 = \theta_2$ contra $H_1 : \theta_1 \neq \theta_2$.

Exercício 9. Seja $\mathbf{X} = (\mathbf{I}, \mathbf{X}_1)$ e $\beta = (\beta_0, \beta_1^\top)^\top$. Mostre que no modelo linear geral de posto completo, em que $\epsilon \sim N_n(0, \sigma \mathbf{I})$, então

$$E(\text{SQReg}/k) = \sigma^2 + (1/k)\beta_1^\top \mathbf{X}_c^\top \mathbf{X}_c \beta_1$$

em que $\mathbf{X}_c = (\mathbf{I} - (1/n)\mathbf{1}\mathbf{1}^\top)\mathbf{X}_1$.

Exercício 10. Sendo $\beta = (\beta_1^\top, \beta_2^\top)^\top$, demonstre o teorema que apresenta a distribuição da estatística do teste sob H_0 e sob H_1 para o teste que tem como hipóteses $H_0 : \beta_2 = 0$ e $H_1 : \beta_2 \neq 0$ no modelo linear geral de posto completo com intercepto em que $\epsilon \sim N_n(0, \sigma \mathbf{I})$.

Exercício 11. Considere o modelo $\mathbf{y} = \mathbf{X}\beta + \epsilon$ com $\epsilon \sim N_n(0, \sigma \mathbf{I})$ e \mathbf{X} de posto completo $k + 1$. Se $\hat{\epsilon} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\beta}$, prove que

- (i) $\text{Cov}(\hat{\epsilon}, \hat{\beta}) = 0$,
- (ii) $\text{Cov}(\epsilon, \hat{\beta}) = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\sigma$,
- (iii) $\text{Cov}(\hat{\epsilon}, \mathbf{y}) = [\mathbf{I} - \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}\mathbf{X}^\top]\sigma$,
- (iv) $\text{Cov}(\hat{\epsilon}, \hat{\mathbf{y}}) = 0$.

Com base nos itens (iii) e (iv), discuta por que é preferível conduzir análise de diagnóstico do modelo a partir da análise gráfica de $\hat{\epsilon} \times \hat{\mathbf{y}}$ em relação à análise gráfica de $\hat{\epsilon} \times \mathbf{y}$.

Exercício 12. Quando a gasolina é colocada em um tanque de um carro, vapores são lançados na atmosfera. Um experimento foi conduzido para verificar se a quantidade de vapor lançada na atmosfera (y) pode ser explicada usando as seguintes 4 variáveis relacionadas com o tanque e a gasolina: x_1 : temperatura do tanque ($^\circ F$), x_2 : temperatura da gasolina ($^\circ F$), x_3 : pressão do vapor no tanque (psi), x_4 : pressão da gasolina no tanque (psi). Os dados estão disponíveis no arquivo DadRegLis2.xls. Assuma que o modelo linear geral com $\epsilon \sim N_n(0, \sigma \mathbf{I})$ e $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \epsilon_i$ é adequado para esses dados. Nos itens que são necessários a realização de teste de hipóteses ou intervalo de confiança, assumo $\alpha = 0,05$

- (a) Construa diagramas de dispersão envolvendo cada uma das variáveis preditoras e a variável resposta.
- (b) Obtenha estimativas de β e σ^2 e interprete as estimativas dos componentes de β em termos do problema em questão. As estimativas estão de acordo com o que era esperado pela análise dos diagramas de dispersão? Caso não estejam, qual é o motivo disso?
- (c) Obtenha estimativa de $\text{cov}(\hat{\beta})$.
- (d) Encontre o coeficiente de determinação do modelo e interprete-o.
- (e) Sendo $\beta = (\beta_0^\top, \beta_1^\top)^\top$, teste $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$. Qual a conclusão do teste em termos do problema?

- (f) Sendo $\beta = (\beta_1^\top, \beta_2^\top)^\top$ e $\beta_2 = (\beta_1, \beta_3)$, teste $H_0 : \beta_2 = 0 \times H_1 : \beta_2 \neq 0$. Qual a conclusão do teste em termos do problema?
- (g) Para cada $j = 1, 2, 3, 4$, teste $H_0 : \beta_j = 0 \times H_1 : \beta_j \neq 0$. Qual a conclusão dos testes em termos do problema? Repita os testes considerando algum método de controle do nível de significância global do teste. As conclusões são as mesmas?
- (h) Obtenha o poder do teste $H_0 : \beta_2 = 0 \times H_1 : \beta_2 \neq 0$, para $\beta_2 = 0,5$, supondo $\sigma^2 = 7,5$. O que significa o valor obtido em termos do problema em questão?
- (i) Teste $H_0 : \beta_2 = 0 \times H_1 : \beta_2 > 0$. Qual a conclusão dos testes em termos do problema?
- (j) Conduza testes de hipóteses com as seguintes hipóteses nulas: $H_{01} : \beta_1 = \beta_2 = 12\beta_3 = 12\beta_4$, $H_{02} : \beta_1 = \beta_2$, $H_{03} : \beta_2 = 12\beta_3$, $H_{04} : \beta_3 = \beta_4$ e $H_{05} : \beta_1 = \beta_2$ e $\beta_3 = \beta_4$.
- (k) Para cada $j = 1, 2, 3, 4$, construa intervalos de confiança para β_j usando algum método de controle do coeficiente de confiança global.
- (l) Obtenha intervalos de confiança para $E(y_0)$ e para uma nova observação y_0 se $\mathbf{x}_0 = (1, 60, 60, 4, 4)^\top$. O que significam esses intervalos em termos do problema em questão?
- (m) Proponha um modelo para ajustar a quantidade de vapor lançada na atmosfera (não incluindo necessariamente todas as variáveis preditoras disponíveis), interprete as estimativas dos parâmetros e realize adequados testes de hipóteses para esse modelo.
- (n) Realize análise de diagnóstico do modelo que você propôs no item anterior. O modelo parece ser adequado para ajustar a quantidade de vapor lançada na atmosfera?

Exercício 13. Em um experimento para investigar o efeito da cor do papel na taxa de resposta de questionários colocado em parabrisas de carro estacionados em supermercados, 15 estacionamentos de supermercados foram escolhidos em uma área metropolitana e cada cor foi atribuída aleatoriamente para cinco estacionamentos. Os dados estão disponíveis no arquivo DadRegLis2.xls.

- (a) Proponha um modelo que assuma que o efeito do tamanho do estacionamento na taxa média de resposta dos questionários varia de acordo com a cor do papel e obtenha as estimativas dos parâmetros desse modelo.
- (b) No modelo proposto no item anterior, teste a hipótese de que o efeito do tamanho do estacionamento na taxa média de resposta dos questionários varia de acordo com a cor do papel. Assuma $\alpha = 5\%$.
- (c) Ajuste um modelo que assuma que o efeito do tamanho do estacionamento na taxa média de resposta dos questionários não varia de acordo com a cor do papel e interprete as estimativas dos parâmetros.
- (d) Baseado no modelo do item anterior e considerando $\alpha = 5\%$, há evidências de que a taxa média de resposta dos questionários varia em função do tamanho do estacionamento? E em função da cor do papel?
- (f) Você escolheria para ajustar a taxa média de resposta dos questionários, o modelo do item (a) ou o modelo do item (c)? Justifique sua resposta.
- (g) Baseado no modelo do item (c), teste a hipótese de que a taxa média de resposta dos questionários é a mesma se a cor é laranja ou verde? Assuma $\alpha = 5\%$.
- (h) Obtenha um intervalo de confiança para a taxa média de resposta e um intervalo de previsão para uma nova observação quando a cor do papel é laranja e o tamanho do estacionamento é 300. Assuma $1 - \alpha = 95\%$

- (i) Realize uma análise de diagnóstico completa do modelo por você escolhido no item (f) e discuta as conclusões.

Exercício 14. Está sendo estudado o consumo de gasolina de um determinado carro em função da velocidade. O consumo do carro foi avaliado em um determinada viagem realizada 12 vezes com diferentes velocidades médias. Os dados estão disponíveis no arquivo DadRegLis2.xls, em que são apresentadas a velocidade média em milhas e o número de milhas percorridas com cada galão de gasolina.

- (a) Faça um diagrama de dispersão entre a variável resposta e a variável preditora e proponha um modelo para este problema.
- (b) Estime os parâmetros do modelo proposto, calcule o coeficiente de determinação do modelo e interprete-o.
- (c) Teste se há ou não relação entre número de milhas percorridas com cada galão de gasolina e a velocidade média. Assuma $\alpha = 1\%$.
- (c) Teste se algum dos parâmetros da curva de regressão pode ser excluído do modelo. Assuma $\alpha = 10\%$.
- (d) Construa intervalos de confiança para os parâmetros do modelo. Assuma $1 - \alpha = 90\%$.
- (e) Obtenha um intervalo de previsão para uma nova observação da variável resposta em que a velocidade média será de 100 milhas. O intervalo obtido é razoável? Por que não?
- (f) Realize uma análise de diagnóstico completa do modelo proposto e discuta as conclusões.

Exercício 15. Um pesquisador está estudando a quantidade de chumbo no solo de determinada região. O objetivo dele é verificar se a quantidade média de chumbo no solo varia de acordo com o tipo de área da região: industrial, residencial e rural. Ele então coletou 300 gramas de solo em 5 diferentes locais de cada um dos tipos de áreas da região. Os dados estão disponíveis no arquivo DadRegLis2.xls.

- (a) Calcule medidas descritivas da quantidade de chumbo por tipo de área. O que a análise descritiva parece sugerir?
- (b) Proponha um modelo, obtenha as estimativas dos parâmetros desse modelo e interprete-as?
- (c) Teste se a quantidade média de chumbo varia em função do tipo de área. Assuma $\alpha = 1\%$.
- (d) Caso você tenha rejeitado a hipótese nula no item anterior, realize comparações múltiplas e discuta as conclusões considerando um nível de significância global de 1% .
- (e) Construa intervalos de confiança com coeficiente de confiança global de 99% para as diferenças entre as áreas (duas a duas) em relação à quantidade média de chumbo no solo.
- (f) Realize uma análise de diagnóstico completa do modelo proposto e discuta as conclusões.

Exercício 16. Um pesquisador está estudando o efeito do tipo de pimentão (nos níveis amarelo, verde e vermelho) e do tipo de cultura (nos níveis orgânico e convencional) na quantidade média de alguns nutrientes. Um dos nutrientes analisados foi a vitamina C. Para cada combinação entre um nível do tipo de pimentão e um nível do tipo de cultura, ele coletou entre 4 e 5 pimentões e mediu a quantidade de vitamina C presente no mesmo.

- (a) Proponha um modelo, obtenha as estimativas dos parâmetros desse modelo e interprete-as?
- (b) Conduza os testes de hipóteses que seriam de interesse do pesquisador controlando, quando necessário, o nível de significância global em 5% . Discuta os resultados obtidos.

- (c) Obtenha um intervalo de confiança para a diferença entre o tipo de cultura orgânico e convencional quando o pimentão é verde em relação a quantidade média de vitamina C. Assuma $1 - \alpha = 95\%$.
- (d) Realize uma análise de diagnóstico completa do modelo proposto e discuta as conclusões.